

Ocena wyszukiwania

- Ocena systemu wyszukiwania to miara tego, jak bardzo system spełnia potrzeby informacyjne użytkowników
 - Problem stanowi inna ocena jakości tego samego zbioru wynikowego przez różnych użytkowników
 - Aby rozwiązać problem wprowadzono różne miary jakości wyszukanego zbioru skorelowane z preferencjami różnych grup użytkowników
 - Aby oceniać systemy wyszukiwania (indeksowania) opracowano testowe kolekcje referencyjne bazujące na założeniach wynikających z badań Cranfielda (1958-1966)
 - Pozwalają one porównywać różne metody rankingu na tych samych zbiorach pytań i dokumentów
-

Ocena wyszukiwania

- Kolekcja referencyjna składa się z:
 - Zbioru D preselekcjonowanych dokumentów,
 - Zbioru I opisów informacji używanej do testowania,
 - Zbioru ocen istotności związanych z każdą parą $[i_m, d_j]$ gdzie $i_m \in I, d_j \in D$.
- Ocena istotności dokumentu ma wartość 0 gdy dokument d_j jest nieistotny dla i_m i 1 w przeciwnym przypadku
- Taka ocena dokonywana jest przez specjalistów

dokładność i kompletność


■ Dane są:

■ I : żądanie informacji,

■ R : zbiór dokumentów istotnych dla I ,

■ A : zbiór odpowiedzi dla I , wygenerowanych przez system wyszukiwania IR,

■ $R \cap A$: iloczyn zbiorów R i A .



dokładność i kompletność

- Kompletność jest częścią istotnych dokumentów (zbiór R), które zostały wyszukane:

$$Recall = \frac{|R \cap A|}{|R|}$$

- Dokładność jest częścią wyszukanych dokumentów (zbiór A), które są istotne:

$$Precision = \frac{|R \cap A|}{|A|}$$

- Definicja dokładności i kompletności zakłada, że wszystkie dokumenty w zbiorze A są testowane
 - Użytkownik widzi uszeregowany zbiór dokumentów i sprawdza je od początku, więc dokładność i kompletność zmieniają się podczas przeglądania zbioru A .
-

dokładność i kompletność

- Wskazane jest wykreślenie zależności dokładności (precision) od kompletności (recall)
- Niech R_{q1} będzie zbiorem dokumentów istotnych dla zapytania q_1 :


$$R_{q1} = \{d_3, d_5, d_9, d_{25}, d_{39}, d_{44}, d_{56}, d_{71}, d_{89}, d_{123}\}$$

- Algorytm wyszukiwania daje zbiór odpowiedzi (dokumeny istotne oznaczone kółkiem)

01. d_{123} •	06. d_9 •	11. d_{38}
02. d_{84}	07. d_{511}	12. d_{48}
03. d_{56} •	08. d_{129}	13. d_{250}
04. d_6	09. d_{187}	14. d_{113}
05. d_8	10. d_{25} •	15. d_3 •

dokładność i kompletność

- Wykres dokładności w funkcji kompletności dla kolejnych dokumentów odpowiedzi



Recall	Precision
0	100
10	100
20	66.6
30	50
40	40
50	33.3
60	0
70	0
80	0
90	0
100	0

dokładność i kompletność

- Rozważmy zapytanie q_2 dla którego zbiór istotnych odpowiedzi jest dany jako:

$$R_{q_2} = \{d_3, d_{56}, d_{129}\}$$

- Algorytm IR przetwarza zapytanie i zwraca następujący ranking:

01. d_{425}	06. d_{615}	11. d_{193}
02. d_{87}	07. d_{512}	12. d_{715}
03. $d_{56} \bullet$	08. $d_{129} \bullet$	13. d_{810}
04. d_{32}	09. d_4	14. d_5
05. d_{124}	10. d_{130}	15. $d_3 \bullet$


- Pierwszy istotny dokument d_{56} zapewnia dokładność i kompletność 33,3%, drugi d_{129} daje kompletność 66,6% i dokładność 25%, trzeci d_3 zapewnia 100% kompletności z dokładnością 20%

dokładność i kompletność

- Dla standardowych poziomów kompletności $r_j = \{0, 1, \dots, 10\}$ dokładność jest interpolowana następująco

$$P(r_j) = \max_{\forall r \mid r \geq r_j} P(r)$$

- Ta zasada interpolacji umożliwia zbudowanie dla ostatniego przykładu następującego wykresu *Precision(Recall)*



Recall	Precision
0	33.3
10	33.3
20	33.3
30	33.3
40	25
50	25
60	25
70	20
80	20
90	20
100	20

dokładność i kompletność

- Zazwyczaj ocenia się średnią jakość wyszukiwania dla zbioru N_q pytań testujących


$$\overline{P(r_j)} = \sum_{i=1}^{N_q} \frac{P_i(r_j)}{N_q}$$

gdzie:

- $\overline{P(r_j)}$ - średnia dokładność na poziomie kompletności r_j ,
- $P_i(r_j)$ – dokładność odpowiedzi na pytanie q_i z poziomem kompletności r_j .

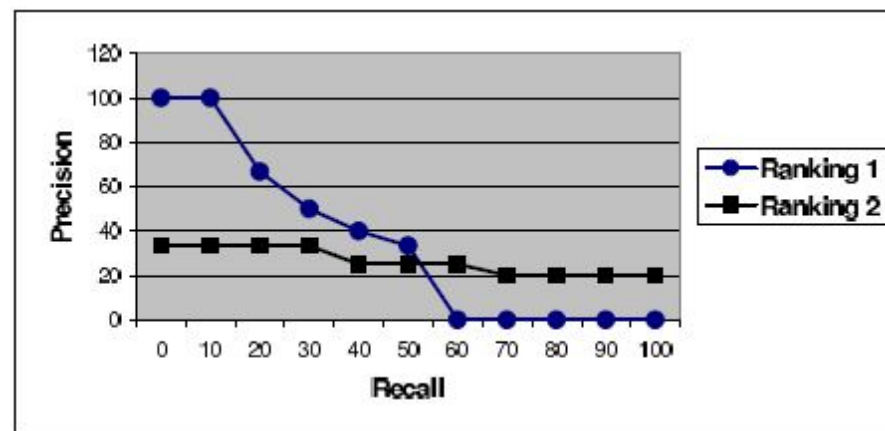
dokładność i kompletność

■ Wykres *Precision(Recall)* uśredniony dla dwóch zapytań q_1 i q_2 :



Recall	Precision
0	66.6
10	66.6
20	49.9
30	41.6
40	32.5
50	29.1
60	12.5
70	10
80	10
90	10
100	10

■ Uśrednione przebiegi *Precision(Recall)* dla 2 różnych algorytmów wyszukiwania:



Dokładność i kompletność

- Dokładność i kompletność są często stosowane do oceny jakości wyszukiwania przez algorytmy IR
 - Poprawna estymacja kompletności zapytania wymaga znajomości wszystkich dokumentów kolekcji testowej
 - Miara *Precision-Recall* nie jest skalarna
 - Jakość algorytmu IR jest mierzona na zbiorze zapytań w trybie wsadowym
 - Dla systemów IR wymagających słabego uporządkowania dokumentów miara *Precision-Recall* może nie być najlepsza
-

Miary $P@5$ i $P@10$

- Użytkownicy wyszukiwarek cenią przede wszystkim dużo istotnych dokumentów na początku rankingu
- Miary $P@5$ i $P@10$ wyznaczają dokładność odpowiednio dla 5 i 10 pierwszych dokumentów; pozwalają ocenić czy użytkownicy uzyskują istotne dokumenty na początku rankingu
- Rozpatrujemy listę dokumentów dla przykładowego pytania q_1 :

01. d_{123} •

02. d_{84}

03. d_{56} •

04. d_6

05. d_8

06. d_9 •

07. d_{511}

08. d_{129}

09. d_{187}

10. d_{25} •

11. d_{38}

12. d_{48}

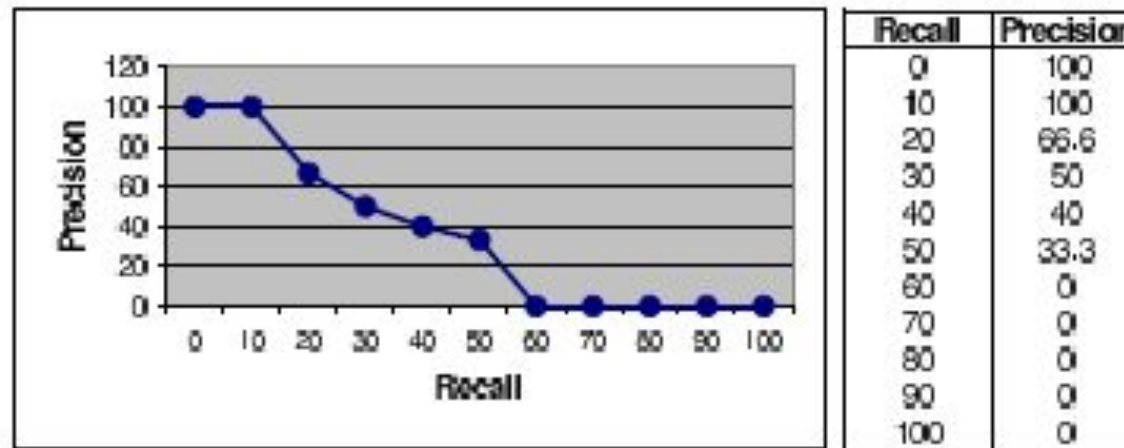
13. d_{250}

14. d_{113}

15. d_3 •

MAP: Mean average precision

- Dla tego pytania $P@5 = 40\%$ i $P@10 = 40\%$
- $P@5$ i $P@10$ można uśredniać w zbiorze 100 zapytań
- MAP to średnia dokładność z wykresu *Precision-Recall*, przy standardowym zestawie kompletności
- Dla zapytania q_1 :



$$MAP_1 = \frac{1 + 0.66 + 0.5 + 0.4 + 0.33 + 0 + 0 + 0 + 0 + 0}{10} = 0.28$$


R-precision

- R-dokładność to dokładność wyznaczona na r -tej pozycji w rankingu odpowiedzi
- Dla pytania q_1 są cztery dokumenty istotne wśród pierwszych 10-ciu zwróconych dokumentów więc R-dokładność wynosi $4/10=0,4$
- R-dokładność może być także uśredniana w zbiorze zapytań
- Może być stosowana do porównywania 2 algorytmów wyszukiwania dla każdego zapytania

- $RP_{A/B}(i) = RP_A(i) - RP_B(i)$
R-dokładność algorytmu A dla i -tego zapytania
 - $RP_B(i)$ – R-dokładność algorytmu B dla i -tego zapytania
-

Histogram dokładności

- Przykładowy histogram porównania algorytmów $RP_{A/B}(i)$ dla 10 różnych zapytań



- Algorytm A jest lepszy w 8 przypadkach na 10

MRR: Mean Reciprocal Rank

■ MRR – dobra miara jakości wyszukiwania gdy interesuje nas pierwsza poprawna odpowiedź – np. adresy URL, strony główne w sieci

■ Jeżeli przyjąć:

■ R_i : ranking odpowiedzi dla zapytania q_i ,

■ $S_{\text{correct}}(R_i)$: pozycja pierwszej poprawnej odpowiedzi w R_i ,

■ S_h : próg pozycji rankingu,

■ to odwrotna ranga $RR(R_i)$ dla pytania q_i jest wyrażona jako

$$RR(\mathcal{R}_i) = \begin{cases} \frac{1}{S_{\text{correct}}(\mathcal{R}_i)} & \text{if } S_{\text{correct}}(\mathcal{R}_i) \leq S_h \\ 0 & \text{otherwise} \end{cases}$$

MRR: Mean Reciprocal Rank

- Średnia odwrotna ranga (MRR) dla zbioru Q z N_q zapytań:

$$MRR(Q) = \sum_i^{N_q} RR(\mathcal{R}_i)$$

Miara E

- łączy dokładność i kompletność w jednym wskaźniku skalarnym uwzględniającym ich proporcje:

$$E(j) = 1 - \frac{1 + b^2}{\frac{b^2}{r(j)} + \frac{1}{P(j)}}$$

- gdzie
 - $r(j)$ – kompletność na j-tej pozycji w rankingu,
 - $P(j)$ – dokładność na j-tej pozycji w rankingu,
 - $b \geq 0$ – ustalony parametr przewagi kompletności nad dokładnością; $b=0 \quad \Downarrow \quad E(j) = 1 - P(j)$ oraz $b \rightarrow \infty \quad \Downarrow \quad E(j) = 1 - r(j)$
 - $E(j)$ – E-metryka na j-tej pozycji w rankingu.
-

Miara F (średnia harmoniczna)

- Dla $b=1$ miara E staje się miarą średniej harmonicznej F :

$$F(j) = \frac{2}{\frac{1}{r(j)} + \frac{1}{P(j)}}$$


- Funkcja F ma wartości w zakresie $[0,1]$; przyjmuje wartość 0 gdy żadne istotne dokumenty nie zostały znalezione lub wartość 1 gdy wszystkie dokumenty odpowiedzi są istotne
 - Duże wartości F wiążą się z dużą dokładnością i kompletnością
-



Miary zorientowane na użytkownika

- Dokładność i kompletność zakładają, że zbiór istotnych dokumentów zwróconych w odpowiedzi na zapytanie nie zależy od użytkowników
 - Różni użytkownicy mogą różnie rozumieć istotność dokumentów
-

Miary zorientowane na użytkownika



- K : zbiór dokumentów znanych użytkownikowi
- $K \cap R \cap A$: zbiór wyszukanych istotnych dokumentów znanych użytkownikowi
- $(R \cap A) - K$: zbiór wyszukanych istotnych dokumentów nieznanymi użytkownikowi

Miary zorientowane na użytkownika

- Współczynnik pokrycia – frakcja dokumentów znanych i istotnych w zbiorze odpowiedzi


$$coverage = \frac{|K \cap R \cap A|}{|K \cap R|}$$

- Współczynnik nowości – frakcja istotnych dokumentów w zbiorze odpowiedzi nieznanymi użytkownikowi

$$novelty = \frac{|(R \cap A) - K|}{|R \cap A|}$$

Wysokie pokrycie, wskazuje że system IR znalazł większość dokumentów oczekiwanych przez użytkownika

Wysoka nowość oznacza znalezienie wielu nowych, istotnych dokumentów



DCG — Discounted Cumulated Gain

- Dokładność i kompletność pozwalają jedynie na binarną ocenę istotności
 - Nie ma rozróżnienia między bardzo i średnio ważnymi dokumentami
 - Zredukowane skumulowane wzmocnienie DCG jest miarą uwzględniającą stopień istotności dokumentów
 - Bardzo istotne dokumenty są preferowane na początku rankingu,
 - Istotne dokumenty na końcu rankingu są mniej ważne
 - Dla k -nastu dokumentów $d[i]$ odpowiedzi na zapytanie q_j tworzy się wektor wzmocnienia $G_j[i]$ odpowiadający przyjętej skali istotności dokumentów np. 0-3.
 - Wzmocnienie 0 mają dokumenty nieistotne.
-

DCG — Discounted Cumulated Gain

- Wektor skumulowany CG_j odpowiada sumowaniu wzmocnień w kolejności rankingu:

$$CG_j[i] = \begin{cases} G_j[1] & \text{if } i = 1; \\ G_j[i] + CG_j[i - 1] & \text{otherwise} \end{cases}$$

- Współczynnik dyskonta stanowi logarytm pozycji rankingu np. $\log_2(i)$,
 - Dzieląc elementy wektora skumulowanego $CG_j[i]$ przez odpowiednie współczynniki dyskonta otrzymuje się współczynnik DCG – zdyskontowanego skumulowanego wzmocnienia.
-

DCG — Discounted Cumulated Gain

$$DCG_j[i] = \begin{cases} G_j[1] & \text{if } i = 1; \\ \frac{G_j[i]}{\log_2 i} + DCG_j[i - 1] & \text{otherwise} \end{cases}$$

- Dla przykładowych zapytań q_1 i q_2 uzyskuje się wektory G_1 , G_2 oraz DCG_1 i DCG_2 .

$$G_1 = (1, 0, 1, 0, 0, 3, 0, 0, 0, 2, 0, 0, 0, 0, 3)$$

$$G_2 = (0, 0, 2, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 3)$$

$$DCG_1 = (1.0, 1.0, 1.6, 1.6, 1.6, 2.8, 2.8, 2.8, 2.8, 3.4, 3.4, 3.4, 3.4, 3.4, 4.2)$$


$$DCG_2 = (0.0, 0.0, 1.3, 1.3, 1.3, 1.3, 1.3, 1.6, 1.6, 1.6, 1.6, 1.6, 1.6, 1.6, 2.4)$$

- Dyskontowane skumulowane wzmocnienia są znacznie mniej wrażliwe na występowanie istotnych dokumentów pod koniec rankingu
-

DCG — Discounted Cumulated Gain

- Funkcje $\overline{CG}[i]$ i $\overline{DCG}[i]$ uśrednione w zbiorze N_q zapytań:

$$\overline{CG}[i] = \sum_{j=1}^{N_q} \frac{CG_j[i]}{N_q}; \quad \overline{DCG}[i] = \sum_{j=1}^{N_q} \frac{DCG_j[i]}{N_q}$$



DCG -znormalizowane

- Dokładność i kompletność są obliczane względem zbioru istotnych dokumentów
- *CG* i *DCG* nie mają odniesienia do żadnej konkretnej bazy, co może utrudniać użycie ich do porównania metod wyszukiwania
- Niech *ICG* i *IDCG* będą idealnymi odpowiednikami *CG* i *DCG* - po wysortowaniu istotności dokumentów w porządku malejącym
- Wprowadza się znormalizowane wartości *CG* i *DCG* :

$$NCG[i] = \frac{\overline{CG}[i]}{\overline{ICG}[i]}; \quad NDCG[i] = \frac{\overline{DCG}[i]}{\overline{IDCG}[i]}$$



DCG -znormalizowane

- Pole pod krzywymi NCG i $NDCG$ reprezentuje jakość algorytmu wyszukiwania z rankingiem
 - Większe pole oznacza lepszy algorytm
 - Kumulowane wzmocnienie zapewnia skalarną miarę jakości wyszukiwania na dowolnej pozycji rankingu
 - Zdyskontowane wzmocnienie pozwala na kontrolę wpływu ważnych dokumentów pod koniec rankingu na ocenę jakości algorytmu
-


BPREF — preferencje binarne

- Paradygmat Cranfielda zakłada ocenę wszystkich dokumentów testowych ze względu na każde zapytanie
 - To może być spełnione tylko dla niewielkich zbiorów
 - Dla dużych zbiorów stosuje się metodę grupowania (pooling)
 - Składa ona do puli tylko najtrafniejsze wyniki uzyskane przez różne algorytmy wyszukiwania,
 - Następnie dokumenty z puli są oceniane w celu porównania metod
 - Miary typu *Precision-Recall* przyjmują za nieistotne wszystkie dokumenty nie wyszukiwane
 - Jest to nie do przyjęcia dla kolekcji złożonych z miliardów dokumentów
-

BPREF — preferencje binarne

- Problem rozwiązuje się poprzez ustalenie preferencji między parami wyszukanych dokumentów zamiast bezpośredniego używania ich rangi - jak to ujęto w przypadku BPREF
 - BPREF mierzy ilość dokumentów nieistotnych poprzedzających dokumenty istotne
 - Ocenia się czy dokument d_j jest preferowany w parze z d_k dla danego zapytania q .
 - Ponadto każdy dokument istotny jest preferowany w parze z nieistotnym
-

BPREF — preferencje binarne



- Dla wymaganej informacji I :
 - R_A : ranking wyliczony przez system IR w odniesieniu do I ,
 - $s_{A,j}$: pozycja dokumentu d_j w R_A ,
 - $[(J - R) \cap A]_{|R|}$: zbiór pierwszych $|R|$ dokumentów w R_A ocenionych jako nieistotne

BPREF — preferencje binarne

- Ilość nieistotnych dokumentów pojawiających się w R_A przed d_j .

$$C(\mathcal{R}_A, d_j) = \|\{d_k \mid d_k \in [(J - R) \cap A]_{|R|} \wedge s_{A,k} < s_{A,j}\}\|$$

- Miara BPREF dla rankingu R_A :

$$Bpref(\mathcal{R}_A) = \frac{1}{|R|} \sum_{d_j \in (R \cap A)} \left(1 - \frac{C(\mathcal{R}_A, d_j)}{\min(|R|, |(J - R) \cap A|)} \right)$$

- Dla każdego istotnego dokumentu d_j w rankingu $Bpref$ akumuluje wagę zmieniającą się odwrotnie do ilości nieistotnych dokumentów poprzedzających
 - Jeśli liczba znanych dokumentów istotnych jest bardzo mała (1 lub 2) stosuje się skorygowaną miarę BPREF-10
-

BPREF — preferencje binarne

- Zapewnia ona minimum 10 istotnych dokumentów

$$C_{10}(\mathcal{R}_A, d_j) = \left\| \{d_k \mid d_k \in [(J - R) \cap A]_{|R|+10} \wedge s_{A,k} < s_{A,j}\} \right\|$$

- Wówczas:

$$Bpref_{10}(\mathcal{R}_A) = \frac{1}{|R|} \sum_{d_j \in (R \cap A)} \left(1 - \frac{C_{10}(\mathcal{R}_A, d_j)}{\min(|R|+10, |(J-R) \cap A|)} \right)$$

Miary korelacji rangowej

- Dokładność i zupełność pozwalają na porównanie istotności wyników uzyskanych przez dwie funkcje rankingowe
 - W pewnych sytuacjach:
 - Nie można bezpośrednio określić istotności dokumentów,
 - Należy ustalić jak bardzo dana funkcja rankingu różni się od drugiej znanej
 - Wówczas interesuje nas porównanie uporządkowania dwóch rankingów
 - Można tego dokonać poprzez funkcje statystyczne zwane miarami korelacji rangowej
-

Miary korelacji rangowej

- Miary korelacji rankingów R_1 i R_2 można wyrazić przez współczynnik korelacji $C(R_1, R_2)$ o następujących właściwościach
 - $-1 \leq C(R_1, R_2) \leq 1$,
 - Jeżeli $C(R_1, R_2) = 1$ zgodność pomiędzy rankingami jest pełna,
 - Jeżeli $C(R_1, R_2) = -1$ niezgodność pomiędzy rankingami jest pełna, tzn. są one odwrócone względem siebie,
 - Jeżeli $C(R_1, R_2) = 0$ dwa rankingi są kompletnie niezależne,
 - Zwiększenie wartości $C(R_1, R_2)$ implikuje zwiększenie zgodności rankingów
-

Współczynnik Spearman'a

■ Współczynnik Spearman'a jest najczęściej używaną miarą korelacji rangowej – bazuje on na różnicach pozycji tego samego dokumentu w różnych rankingach

documents	$s_{1,j}$	$s_{2,j}$	$s_{1,j} - s_{2,j}$	$(s_{1,j} - s_{2,j})^2$
d_{123}	1	2	-1	1
d_{84}	2	3	-1	1
d_{56}	3	1	+2	4
d_6	4	5	-1	1
d_8	5	4	+1	1
d_9	6	7	-1	1
d_{511}	7	8	-1	1
d_{129}	8	10	-2	4
d_{187}	9	6	+3	9
d_{25}	10	9	+1	1
Sum of Square Distances				24

■ Dane z 10 dokumentów wyszukanych przez 2 rankingi R_1 i R_2 . $s_{1,j}$ and $s_{2,j}$ są pozycjami j -tego dokumentu w tych rankingach

Współczynnik Spearman'a

- Przy porządkowaniu K dokumentów maksimum sumy kwadratów różnic pozycji rankingu wynosi

$$\frac{K \times (K^2 - 1)}{3}$$

- Przy pełnej niezgodności rankingów dla $K=10$ maksimum to wynosi $(10 \times (10^2 - 1))/3 = 330$
- Współczynnik Spearmana korelacji rang $S(R_1, R_2)$:

$$S(\mathcal{R}_1, \mathcal{R}_2) = 1 - \frac{6 \times \sum_{j=1}^K (s_{1,j} - s_{2,j})^2}{K \times (K^2 - 1)}$$

- zmienia się w zakresie $[-1, 1]$, K – rozmiar porównywanych zbiorów
-

Współczynnik Spearman'a

■ Przykład:

$$S(\mathcal{R}_1, \mathcal{R}_2) = 1 - \frac{6 \times 24}{10 \times (10^2 - 1)} = 1 - \frac{144}{990} = 0.854$$

documents	$s_{1,j}$	$s_{2,j}$	$s_{i,j} - s_{2,j}$	$(s_{1,j} - s_{2,j})^2$
d_{123}	1	2	-1	1
d_{84}	2	3	-1	1
d_{56}	3	1	+2	4
d_6	4	5	-1	1
d_8	5	4	+1	1
d_9	6	7	-1	1
d_{511}	7	8	-1	1
d_{129}	8	10	-2	4
d_{187}	9	6	+3	9
d_{25}	10	9	+1	1
Sum of Square Distances				24

Współczynnik tau Kendall'a

- Posiada on naturalną i intuicyjną interpretację

$$\tau(\mathcal{R}_1, \mathcal{R}_2) = P(\mathcal{R}_1 = \mathcal{R}_2) - P(\mathcal{R}_1 \neq \mathcal{R}_2)$$

- gdzie

- $P(R_1 = R_2)$ – znormalizowana ilość zgodnych par dokumentów (concordant), dla których różnice w pozycjach rankingu par dokumentów $[d_k, d_j]$: $s_{1,k} - s_{1,j}$ oraz $s_{2,k} - s_{2,j}$ są tego samego znaku dla 2 porównywanych metod
- $P(R_1 \neq R_2)$ – znormalizowana ilość niezgodnych par dokumentów (discordant), dla których różnice w pozycjach rankingu par dokumentów $[d_k, d_j]$: $s_{1,k} - s_{1,j}$ oraz $s_{2,k} - s_{2,j}$ są różnych znaków

- Jeżeli przyjąć

- $\Delta(R_1, R_2)$: liczba niezgodnych par dokumentów w rankingach R_1 i R_2 ,
- $K(K - 1) - \Delta(R_1, R_2)$: liczba zgodnych par dokumentów,

Współczynnik tau Kendall'a

■ Wówczas:

$$P(\mathcal{R}_1 = \mathcal{R}_2) = \frac{K(K-1) - \Delta(\mathcal{R}_1, \mathcal{R}_2)}{K(K-1)}$$

$$P(\mathcal{R}_1 \neq \mathcal{R}_2) = \frac{\Delta(\mathcal{R}_1, \mathcal{R}_2)}{K(K-1)}$$

■ co daje:

$$\tau(\mathcal{R}_1, \mathcal{R}_2) = 1 - \frac{2 \times \Delta(\mathcal{R}_1, \mathcal{R}_2)}{K(K-1)}$$

■ Przykład: 5 dokumentów w 2 rankingach

documents	$s_{1,j}$	$s_{2,j}$	$s_{1,j} - s_{2,j}$
d_{123}	1	2	-1
d_{84}	2	3	-1
d_{56}	3	1	+2
d_6	4	5	-1
d_8	5	4	+1

Współczynnik tau Kendall'a

- Uporządkowane pary dokumentów w rankingu R_1

$[d_{123}, d_{84}]$	$[d_{123}, d_{56}]$	$[d_{123}, d_6]$	$[d_{123}, d_8]$	$C, D, C, C,$
$[d_{84}, d_{56}]$	$[d_{84}, d_6]$	$[d_{84}, d_8]$		$D, C, C,$
$[d_{56}, d_6]$	$[d_{56}, d_8]$			$C, C,$
$[d_6, d_8]$				D

- Uporządkowane pary dokumentów w rankingu R_2 :

$[d_{56}, d_{123}]$	$[d_{56}, d_{84}]$	$[d_{56}, d_8]$	$[d_{56}, d_6]$	$D, D, C, C,$
$[d_{123}, d_{84}]$	$[d_{123}, d_8]$	$[d_{123}, d_6]$		$C, C, C,$
$[d_{84}, d_8]$	$[d_{84}, d_6]$			$C, C,$
$[d_8, d_6]$				D

- Dla $K=5$ dokumentów $K(K-1)=20$ oraz

$$\begin{aligned}\tau(\mathcal{R}_1, \mathcal{R}_2) &= \frac{14}{20} - \frac{6}{20} \\ &= 0.4\end{aligned}$$

